

Benemérita Universidad Autónoma de Puebla
Facultad de Ciencias de la Computación

Técnicas de inteligencia artificial

Reporte: Ejemplo de un algoritmo genético



BUAP

Docente: Abraham Sánchez López

Alumno

Taisen Romero Bañuelos

Matrícula

202055209

Algoritmo genético en C

Para poder identificar más fácilmente los pasos del algoritmo revisé de nuevo el algoritmo que venía en las diapositivas de “Computación evolutiva”.

- Ejemplo de un algoritmo genético simple:

```
Generar una población inicial
Calcular la función de evaluación de cada individuo
Mientras no TERMINADO hacer
  Inicio // producir nueva generación
    Para tamaño_población/2 hacer
      Inicio // ciclo reproductivo
        Seleccionar dos individuos de la anterior generación, para el cruce (probabilidad de selección
        proporcional a la función de evaluación del individuo).
        Cruzar con cierta probabilidad los dos individuos obteniendo dos descendientes.
        Mutar los dos descendientes con cierta probabilidad.
        Calcular la función de evaluación de los dos descendientes mutados.
        Insertar los dos descendientes mutados en la nueva generación.
      Fin
    Si la población ha convergido entonces TERMINADO = CIERTO
  Fin
Fin
```

Esta estrategia fue realmente efectiva. En el código de `geneti.c` pude identificar que primero se definen las variables que se mencionan al inicio de la diapositiva (tamaño de la población, probabilidad de cruce, probabilidad de mutación, número máximo de generaciones, etc.), esto pues es obvio, siempre en un programa C se empieza definiendo variables, pero hasta en nuestro algoritmo de las diapositivas se manifiesta esta inicialización de las cosas. Lo interesante viene después, pues, entramos al bucle para crear una generación con base a los parámetros asignados. Cada generación selecciona dos individuos (mates) para hacer un torneo para seleccionar al mejor (con `select()` se hace el torneo) y luego realiza un cruce con la probabilidad de PC (o sea, cabe la posibilidad de que no se reproduzcan). En caso de que hayan tenido un cruce exitoso se aplica la mutación con la probabilidad PM (que por curiosidad le puse 5 para que salgan cromosomas bien mutantes). Luego se calcula su aptitud con base a la función $f(x) = x^2$ normalizada, después se hace un reporte de la nueva generación y se actualiza la población intercambiando `oldpop` \longleftrightarrow `newpop`. Este proceso se repite Gmax veces (o sea, el número de generaciones que el usuario introduzca).

Ahora, pasemos de la teoría a lo empírico para entender mejor cómo funciona el algoritmo.

Para este ejemplo usé los siguientes parámetros:

- Tasa de mutación (Pm): 5.0.
- Probabilidad de cruce (Pc): 0.8.
- Número máximo de generaciones (Gmax): 2.

- Semilla para aleatoriedad (Rseed): 0.7.
- Tamaño de la población (popsize): 100.
- Longitud del cromosoma (codesize): 16.

Obtuve los siguientes resultados para la generación 0:

P O P U L A T I O N				R E P O R T							
Generation #	0			Generation #	1						
num	string	x	fitness	parents	x1	x2	mut	place	string	x	fitness
1)	0100111100100011	20259.0000	0.0956	(1, 4)	12	14	Y	2	0110111100100111	28455.0000	0.1885
2)	0010100101000010	10562.0000	0.0260	(1, 4)	12	14	Y	13	1011001110010111	45975.0000	0.4921
3)	000111011110011	7923.0000	0.0146	(6, 7)	0	0	Y	4	0101010011110111	21751.0000	0.1102
4)	1011001110010111	45975.0000	0.4921	(6, 7)	0	0	Y	7	1101110100011100	56604.0000	0.7460
5)	0010010100010110	9494.0000	0.0210	(9, 11)	0	0	Y	9	1110110000000111	60423.0000	0.8501
6)	0101110011110111	23799.0000	0.1319	(9, 11)	0	0	Y	1	1011001001011011	45659.0000	0.4854
7)	1101110000011100	56348.0000	0.7393	(14, 15)	13	15	Y	12	1001101010100010	39586.0000	0.3649
8)	0010101011001101	10957.0000	0.0280	(14, 15)	13	15	Y	12	1110100101010111	59735.0000	0.8308
9)	1110110001000111	60487.0000	0.8519	(18, 46)	4	5	Y	12	1110001010100000	58016.0000	0.7837
10)	1001110111111110	40446.0000	0.3809	(18, 46)	4	5	Y	11	1111111000111100	65084.0000	0.9863
11)	1111001001010111	62043.0000	0.8963	(56, 23)	0	2	Y	9	1000111100001001	36617.0000	0.3122
12)	1010000010100011	41123.0000	0.3938	(56, 23)	0	2	Y	3	1011001101000110	45894.0000	0.4904
13)	011111111010111	32731.0000	0.2494	(71, 28)	4	8	Y	1	1100000100011000	49432.0000	0.5689
14)	1001101010101110	39598.0000	0.3651	(71, 28)	4	8	Y	9	1001110010101101	40109.0000	0.3746
15)	1110100101010111	59739.0000	0.8309	(30, 32)	3	10	Y	14	1100110111101100	52716.0000	0.6471
16)	0010001100110110	9014.0000	0.0189	(30, 32)	3	10	Y	0	1111000011100010	61666.0000	0.8854
17)	0011100001010100	14420.0000	0.0484	(24, 36)	10	11	Y	8	1010100111100010	43490.0000	0.4404
18)	1110101010101000	60072.0000	0.8402	(24, 36)	10	11	Y	9	1100100111110110	51702.0000	0.6224
19)	0000111000110101	3637.0000	0.0031	(86, 39)	5	10	Y	8	1111110010010110	64662.0000	0.9735

```

Generation # 0 Accumulated Statistics:
Total Crossovers = 38, Total Mutations = 100
min = 0.006600 max = 0.986300 avg = 0.536906 sum = 53.690600
Best individual in this generation = 111111000111100
Global Best Individual so far, Generation # 0:
String = 111111000111100 Fitness = 0.986300

```

Ya desde esta generación la aptitud promedio mejoró, pasó de 0.5369 a 0.6464. El macho alfa de esta generación fue “111111000111100”, que al parecer tuvo de hijo al mejor de la siguiente generación (pronto llegaremos a eso).

En la segunda generación hubo un aumento en la variabilidad genética porque se hicieron 74 cruces y 200 mutaciones (un gran aumento con respecto a la generación pasada que tuvo 38 cruces y 100 generaciones). También, la aptitud máxima (0.98) roza el 1.0, lo que sugiere que el algoritmo ha encontrado una solución óptima o cercana a ella. Lo más interesante es que el mejor individuo de esta generación parece conservar una buena parte del cromosoma del mejor individuo de la generación pasada.

```

Generation # 1 Accumulated Statistics:
Total Crossovers = 74, Total Mutations = 200
min = 0.003500 max = 0.998700 avg = 0.646376 sum = 64.637600
Best individual in this generation = 111111111010110
Global Best Individual so far, Generation # 1:
String = 111111111010110 Fitness = 0.998700

```

Algo que noté mientras revisaba la lista de individuos es que aquellos que tenían muchos unos tenían una mejor aptitud. Véase el contraste entre el individuo subrayado (con una aptitud del 0.3%) y el primero, con una aptitud notablemente superior.

```
1111111010010110 65174.0000 0.9890
0101110010010110 23702.0000 0.1308
1110101111010110 60374.0000 0.8487
1110010100110010 58674.0000 0.8016
0001010000111011 5179.0000 0.0062
1000100100101110 35118.0000 0.2872
0000111100101111 3887.0000 0.0035
```

Si nos ponemos a pensar, obtuvimos una aptitud elevada (0.98) demasiado rápido, en tan sólo dos generaciones nos acercamos a la solución óptima, ¿Cómo fue posible esto?, quizás se deba a que me excedí en la probabilidad de mutación, pues, los valores típicos oscilan entre 1.0 y 0. Esto pudo haber favorecido la exploración del espacio de soluciones, pero también pudo haber causado una mayor aleatoriedad en la evolución. Además, puse una buena tasa de cruce (0.8) pensando en que es raro que los individuos se reproduzcan sin éxito, seguramente eso también ayudó a la mezcla de los cromosomas.

Me causa ruido que según nuestro algoritmo tener una mutación excesiva es bueno para la aptitud de los individuos. Si nos ponemos a pensar con detenimiento, la mutación excesiva es igual de perjudicial o más que el elitismo de individuos, así que para poder observar mejor la tendencia del comportamiento de nuestros parámetros voy a extender las generaciones a 50.

```
Generation # 49 Accumulated Statistics:
Total Crossovers = 1995, Total Mutations = 5000
min = 0.216400 max = 0.999800 avg = 0.854819 sum = 85.481900
Best individual in this generation = 1111111111111001
Global Best Individual so far, Generation # 25:
String = 1111111111111111 Fitness = 1.000000
```

Definitivamente se corroboró mi teoría de que cuantos más unos mejor es la aptitud. Sin embargo, creo que tener un fitness=1.0 es una señal de sobreentrenamiento. En promedio, la aptitud es de 0.8, lo cual está bien pero si consideramos que nuestro mejor individuo es prácticamente un dios frente a los demás creo que no estamos generando un buen modelo. Nuestro Dr. Manhattan (1111111111111111) tiene un comportamiento particular. Apareció en la generación 25 pero rara vez aparece dentro de las generaciones, a excepción de la generación 41, ahí tuvo hijo pero de forma anti-intuitiva tuvo un hijo con una aptitud extremadamente baja (0.2).

62)	1111111111111111	65535.0000	1.0000		(21, 23)	0	0	Y	0	0111101010010000	31376.0000	0.2292
63)	1110111101101101	61293.0000	0.8747		(26, 27)	0	0	Y	13	1111111111101011	65515.0000	0.9994
64)	1111111110001010	65418.0000	0.9964		(26, 27)	0	0	Y	2	1101111100001110	57102.0000	0.7592

97)	1110101101000110	60230.0000	0.8447		(97, 62)
98)	0111111100010111	32535.0000	0.2465		(97, 62)
99)	11110111111010010	63442.0000	0.9371		(96, 66)

Bien, además de que hasta a los dioses los castigan, ¿Qué interpretación podemos sacar de este resultado?, pues que los individuos con una aptitud perfecta son escasos entre generaciones porque al reproducirse lo más probable es que se reproduzcan con un individuo con una peor aptitud, lo que significa que la aptitud de sus hijos se verá comprometida. Sacándolo del contexto del programa, quizá eso explique por qué a veces las leyendas humanas casi no tienen hijos que sean igual de impresionantes, y no sólo eso, también explicaría por qué es extraño que surjan individuos de este estilo, bien pueden pasar generaciones hasta que se de otro caso de un individuo excepcional.